HW1

利用統計方法 檢測學生總成績

111426025 盧盈穎

2022/09/19



目錄


01 研究動機

02 資料集介紹

03 研究方法

04 延伸問題





01

研究動機

O1 研究動機 Research motivation

• 「龍生龍鳳生鳳,老鼠生的孩子會打洞」_{-俗諺}

學生學習成績是否受學生有沒有先修上課或父母的 教育程度等因素影響

02

資料集介紹



02 資料集介紹/資料前處理/資料觀察

kaggle

使用kaggle所提供Student Performance In Exams資料集

https://www.kaggle.com/code/spscientist/student-performance-in-exams/data

02. 資料集介紹/資料前處理/資料觀察 Intro. to Datasets

gender	race/ ethnicity	parental level of education	lunch	test preparation course	math score	reading score	writing score
female	group B	bachelor's degree	standard	none	72	72	74
female	group C	some college	standard	completed	69	90	88
female	group B	master's degree	standard	none	90	95	93
		•		•			
		•					
•	-	•	-	-	•	•	•
female	group D	some college	free/ reduced	none	77	86	86

總共:1000筆資料

02 資料集介紹/資料觀察/資料前處理

資料欄位統計敘述

主欄位	類別	總數	
tost proparation source	none	2	
test preparation course	completed	2	
	some college		
	associate's degree		
payantal lavel of advection	high school		
parental level of education	some high school	6	
	bachelor's degree		
	master's degree		

以上為本次研究會使用到的資料欄位。

02 資料集介紹 / 資料觀察 / **資料前處理**

1. 檢查資料型態

df. dtypes gender object race/ethnicity object parental level of education object 1unch object test preparation course object int64 math score reading score int64 writing score int64 dtype: object

2. 檢查資料是否有空值

```
df.isnull().sum()

gender 0
race/ethnicity 0
parental level of education 0
lunch 0
test preparation course 0
math score 0
reading score 0
writing score 0
dtype: int64
```

() 資料集介紹 / 資料觀察 / 資料前處理

3. 將數學、閱讀、寫作三科分數進行加總及平均,得到學生總成績平均。

```
df['Total'] = (df['math score']+df['reading score']+df['writing score'])/3

for i in range(len(df['Total'])):
    df['Total'][i] = round(df['Total'][i],2)
```

4. 删除多餘的欄位。

```
df = df.drop('math score',axis=1)
df = df.drop('reading score',axis=1)
df = df.drop('writing score',axis=1)
```



03

研究方法

03.研究方法 Methods

目的:

學生有沒有先修上課是否會影響學生總成績?

統計方法:

T-Test 檢測學生有沒有上先修課程是否會影響學生總成績。

03.研究方法

將1000筆學生成績資料進行分類、去除不必要欄位整理後資料

實際程式中跑的資料

	Total	Test
0	72.67	none
1	92.67	none
2	49.33	none
3	76.33	none
•		
999	74.33	completed

test preparation course

```
df_no = df[df['test preparation course']=="none"]
df_co = df[df['test preparation course']=="completed"]
```


df_no.count()		df_co.count()	
gender race/ethnicity parental level of education lunch test preparation course Total dtype: int64	642 642 642 642 642 642	gender race/ethnicity parental level of education lunch test preparation course Total dtype: int64	358 358 358 358 358 358 358


兩種類別數量皆大於30

03.研究方法

1. 檢查資料集是否符合常態分配

根據中央極限定理,樣本數夠大,樣本和減去平均數再除以標準差,將會趨近平均數為0。





03 研究方法

2. 檢查資料集是否為同性質

```
print('None:',np.var(df_shs_RR),'Completed:' ,np.var(df_hs_RR))
None: 200.94522052411176 Completed: 169.49196703676537
223.26228499734717/181.60957426853395
```

1. 229353055292251

此資料集方差的比率為1.2293,小於4,表示可以假設總體方差相等。

3. 虚無假設

 H_0 : $\mu_{A1} = \mu_{A2}$

 H_a :學生有沒有上先修課程考試成績平均值不完全相同

 $\alpha = 0.05$

03 研究方法

結論:

```
mean1 = np.mean(df_shs_RR)
mean2 = np.mean(df hs RR)
std1 = np.std(df shs RR)
std2 = np.std(df hs RR)
nobs1 = len(df shs RR)
nobs2 = len(df_hs_RR)
modified_std1 = np.sqrt(np.float32(nobs1)/np.float32(nobs1-1)) * std1
modified_std2 = np.sqrt(np.float32(nobs2)/np.float32(nobs2-1)) * std2
statistic, pvalue = stats.ttest_ind_from_stats( mean1=mean1, std1=modified_std1, nobs1=nobs1,
                            mean2=mean2, std2=modified_std2, nobs2=nobs2 )
statistic
-8.391129735727805
pvalue
```

p<0.05,拒絕 H_0 ,學生有沒有上先修課程考試成績平均值不完全相同。

因此,學生有上先修課程和沒 有上先修課程有顯著差異。

1.631376440841688e-16

04

延伸問題



目的:

如果加入父母的教育程度、學生有沒有上先修課程是否會影響學生總成績?

統計方法:

Two way ANOVA 檢測學生有沒有上先修課程和父母的教育程度是否會影響學生總成績。

1. 取得資料

	Total	Parent	Test
0	72.67	bachelor's degree	none
1	92.67	master's degree	none
2	49.33	associate's degree	none
3	76.33	some college	none
		•	
		•	-
-	•	•	•
999	74.33	some college comple	

2. 檢查Parent欄位中各類別數量

```
a = N_df[N_df['Parent']=="some high school"]
b = N_df[N_df['Parent']=="high school"]
c = N_df[N_df['Parent']=="associate's degree"]
d = N_df[N_df['Parent']=="some college"]
e = N_df[N_df['Parent']=="bachelor's degree"]
f = N_df[N_df['Parent']=="master's degree"]
```

bachelor	's degree	mater	's degree
----------	-----------	-------	-----------


como high school	high school	accociato' c dograd	como collogo
some high school	riigii scrioot	associate's degree	some college

a.count()	b. count()	c.count()	d.count()
Total 179	Total 196	Total 222	Total 226 Test 226 Parent 226 dtype: int64
Test 179	Test 196	Test 222	
Parent 179	Parent 196	Parent 222	
dtype: int64	dtype: int64	dtype: int64	

以上各類別數量皆大於30,固可根據中央極限定理視為常態分佈

3. 檢查資料集是否符合常態分配

根據中央極限定理,樣本數夠大,可視為常態分佈。以下為Parent各類別的分布圖:



4. 檢查資料集是否有相同變異數

Test 因子

stats.levene(aaa1, bbb1)

LeveneResult(statistic=2.8836464775685, pvalue=0.08979489565937057)

Parent因子

stats. levene (aaa, bbb, ccc, ddd, eee, fff)

LeveneResult(statistic=0.5080914858918754, pvalue=0.7703017393081184)

兩因子的P值皆大於0.05,故他們的變異數相同

5. 虚無假設

Test 因子 μ_{A1} : 學生有上先修課程

 μ_{A2} : 學生沒有上先修課程

 $H_0: \mu_{A1} = \mu_{A2}$

 H_a : 學生有沒有上先修課程成績平均值不完全相同

Parent因子 μ_{B1} : some college μ_{B4} : some high school

 μ_{B2} : associate's degree μ_{B5} : bachelor's degree

 μ_{B3} : high school μ_{B6} : master's degree

 H_0 : $\mu_{B1} = \mu_{B2} = \mu_{B3} = \mu_{B4} = \mu_{B5} = \mu_{B6}$

Ha: 至少有一組父母的教育程度成績平均值不完全相同

結論:

```
import statsmodels.api as sm
from statsmodels.formula.api import ols
mod = ols('Total ~ Test+Parent+Test:Parent', data = N df).fit()
sm. stats. anova_1m(mod, typ = 2)
                                                PR(>F)
                   sum_sq
             12862.375092
                            1.0 70.906113 1.306095e-16
    Test
                            5.0 10.914927 3.058591e-10
  Parent
              9899.843741
Test:Parent
               561.825220 5.0 0.619432 6.850331e-01
 Residual
            179223.286814 988.0
                                     NaN
                                                  NaN
```

學生有沒有上先修課程,p<0.05,拒絕 H_0 ,學生有上先修課程和沒有上先修課程有顯著差異。 父母的教育程度,p<0.05,拒絕 H_0 ,所以父母是碩士還是高中畢業對於學生總成績會產生顯著差異。

Tukey HSD -父母的教育程度

```
import statsmodels.api as sm
mc = sm.stats.multicomp.MultiComparison(N_df["Total"], N_df["Parent"])
mc_result = mc.tukeyhsd()
print(mc_result)
```

Multiple Comparison of Means - Tukey HSD, FWER=0.05


group1	group2	meandiff	p-adj	1ower	upper	reject
associate's degree	_	2.355	0.6515	-2. 1735	6.8835	Fa1se
associate's degree	high school	-6. 4718	0.001	-10.3678	-2.5758	True
associate's degree	master's degree	4.0297	0.3574	-1.7925	9.8518	False
associate's degree	some college	-1.0929	0.9	-4.849	2.6633	False
associate's degree	some high school	-4. 4613	0.0183	-8. 4543	-0.4683	True
bachelor's degree	high school	-8.8268	0.001	-13.4584	-4. 1952	True
bachelor's degree	master's degree	1.6747	0.9	-4.6634	8.0127	Fa1se
bachelor's degree	some college	-3.4479	0.2476	-7.9625	1.0667	False
bachelor's degree	some high school	-6.8163	0.001	-11.5298	-2.1028	True
high school	master's degree	10.5015	0.001	4. 5988	16.4041	True
high school	some college	5.3789	0.0011	1. 4991	9. 2587	True
high school	some high school	2.0105	0.7022	-2.0991	6.12	False
master's degree	some college	-5.1225	0.1204	-10.9339	0.6888	False
master's degree	some high school	-8.491	0.001	-14.4582	-2.5238	True
some college	some high school	-3.3685	0.1508	-7.3457	0.6088	False

在畫黃色底線的類別,由於他們的p值小 於0.05,他們之間存在差異。


以下會以區間圖及箱形圖顯示他們之間 的交互關係是否存在差異

Tukey HSD - 父母的教育程度

```
import matplotlib.pyplot as plt
rows = mc_result.summary().data[1:]
plt.hlines( range(len(rows)), [row[4] for row in rows], [row[5] for row in rows] )
plt.vlines( 0, -1, len( rows )-1, linestyles='dashed' )
plt.gca().set_yticks( range( len( rows ) ) )
plt.gca().set_yticklabels( [ f'{x[0]}-{x[1]}' for x in rows ] )
plt.show()
```



Tukey HSD - 父母的教育程度





謝納大家

111426025 盧盈穎